



# MI

## Metody Identyfikacji

wykład #8

1. *Modele NARMAX*
2. *Szeregi nieliniowe różnych funkcji bazowych:*
  - a) *Volterre*
  - b) *Laguerre*
  - c) *...*

# Modele NARMAX

- Nieliniowe modele opisane za pomocą równania różnicowego

- postać ogólna


$$y(k+1) = f(y(k), y(k-1), \dots, u(k), u(k-1), \dots)$$

- Zależność od opóźnionych  $y(k)$  – *autoregresja*
    - Zależność od opóźnionych  $u(k)$  – *ruchoma średnia*
    - Wiele wersji, jak na przykład NAR, NMA, NARMA, NARX, etc ...

- Postacie iloczynowe

$$y(k+1) = a_1 y(k) y(k-1) + a_2 y(k) u(k-1) + a_3 u(k) u(k)$$

# Modele kawałkami liniowe



# Modele Takagi-Sugeno

- W 1985 roku Takagi i Sugeno zaproponowali nowy schemat wnioskowania. Metoda ta zmieniła standardową postać reguł i stanowi rozwinięcie najprostszego układu rozmytego z singletonami po stronie następnika reguły.
- Zakładając, że układ ma  $N$  sygnałów wejściowych  $x_1, x_2, \dots, x_N$  można zapisać poszczególną regułę w postaci:

$$R^2: \quad \textit{jeśli } x_1 \textit{ jest } A1 \textit{ i } x_2 \textit{ jest } A2 \textit{ i } \dots x_N \textit{ jest } AN \textit{ to } y=f(x_1, x_2, \dots, x_N)$$

- gdzie funkcja  $f(x_1, x_2, \dots, x_N)$  jest liniową kombinacją wejść

$$f(x_1, x_2, \dots, x_N) = a_0 + a_1 x_1 + a_2 x_2 + \dots + a_N x_N$$

# Model NARMAX a model Takagi-Sugeno

- Przyjmujemy opis za pomocą modelu ARX

$$A(z^{-1})y_k = B(z^{-1})z^{-d}u_k + e_k$$

$$A(z^{-1}) = 1 + a_1 z^{-1} + \dots + a_{N_a} z^{-N_a}$$

$$B(z^{-1}) = b_0 + b_1 z^{-1} + \dots + b_{N_b} z^{-N_b}$$

$$Ee_k = 0 \quad Ee_k^2 = \sigma^2$$

- Jedna reguła opisuje model lokalny

$$\hat{y}(t+1) = a_{1,i}y(t) + \dots + a_{N_a,i}y(t - N_a) + b_{0,i}u(t - d + 1) + \dots + b_{N_b,i}u(t - d - N_b)$$

- Natomiast złożenie wszystkich reguł

$$w_i(z(t)) = \frac{|z(t) \text{ jest } Z_i|}{\sum_{j=1}^M |z(t) \text{ jest } Z_j|}$$

- gdzie  $|z(t) \text{ jest } Z_i|$  oznacza stopień przynależności  $z(t)$  do  $Z_i$ .

# Model NARMAX a model Takagi-Sugeno

- Model możemy przepisać jako

$$\hat{y}(t+1) = \sum_{i=1}^M \left[ a_{1,i}y(t) + \dots + a_{N_a,i}y(t - N_a) + b_{0,i}u(t-d+1) + \dots + b_{N_b,i}u(t-d-N_b) \right] w_i(z(t))$$

- A uwzględnivszy zależność na wnioskowanie

$$\hat{y}(t+1) = \frac{\sum_{i=1}^M \left[ a_{1,i}y(t) + \dots + a_{N_a,i}y(t - N_a) + b_{0,i}u(t-d+1) + \dots + b_{N_b,i}u(t-d-N_b) \right] \cdot |z(t) \text{ jest } Z_i|}{\sum_{i=1}^M |z(t) \text{ jest } Z_i|}$$

- Całość można przepisać do postaci jednolitej



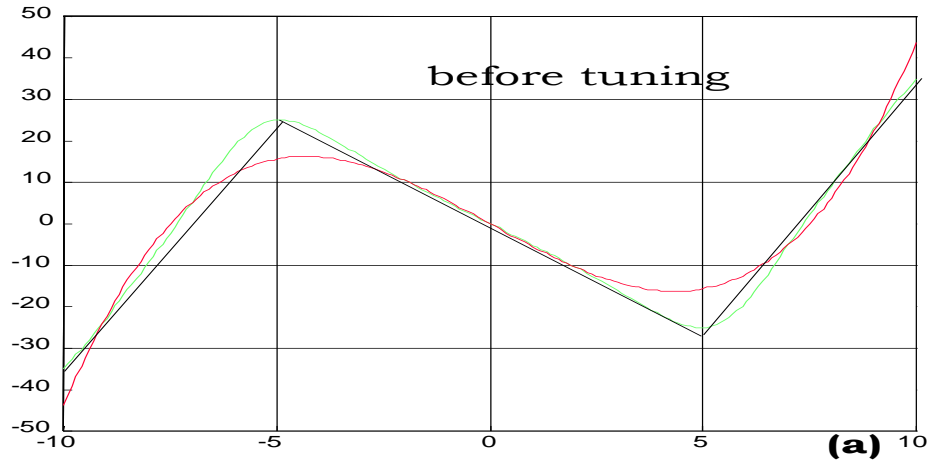
$$y(t+1) = a_1(z(t))y(t) + \dots + a_{N_a}(z(t))y(t - N_a) +$$

$$b_0(z(t))u(t-d+1) + \dots + b_{N_b}(z(t))u(t-d-N_b)$$

$$a_i(z(t)) = \sum_{j=1}^M a_{i,j} w_j(z(t))$$

$$b_i(z(t)) = \sum_{j=1}^M b_{i,j} w_j(z(t))$$

# Rozmyte modelowanie kawałkami liniowe



# Modele NARMAX a sieci neuronowe

- Wyobraźmy sobie sieć rekurencyjną
- $y(n+q) = \Phi(\mathbf{x}(n), \mathbf{u}_q(n))$ , gdzie  $q$  jest rozmiarem przestrzeni stanów i  $\Phi: R^{2q} \rightarrow R$ .
- Zakładamy, że sieć jest obserwowalna, tzn.  $\mathbf{x}(n) = \Psi(\mathbf{y}_q(n), \mathbf{u}_{q-1}(n))$  where  $\Psi: R^{2q} \rightarrow R$ .
- $y(n+q) = F(\mathbf{y}_q(n), \mathbf{u}_q(n))$  gdzie  $\mathbf{u}_{q-1}(n)$  jest zawarte w  $\mathbf{u}_q(n)$  jako pierwsze  $(q-1)$  elementy, a przekształcenie nieliniowe  $F: R^{2q} \rightarrow R$  uwzględnia zarówno  $\Psi$  jak i  $\Phi$ .
- $y(n+1) = F(y(n), \dots, y(n-q+1), u(n), \dots, u(n-q+1))$

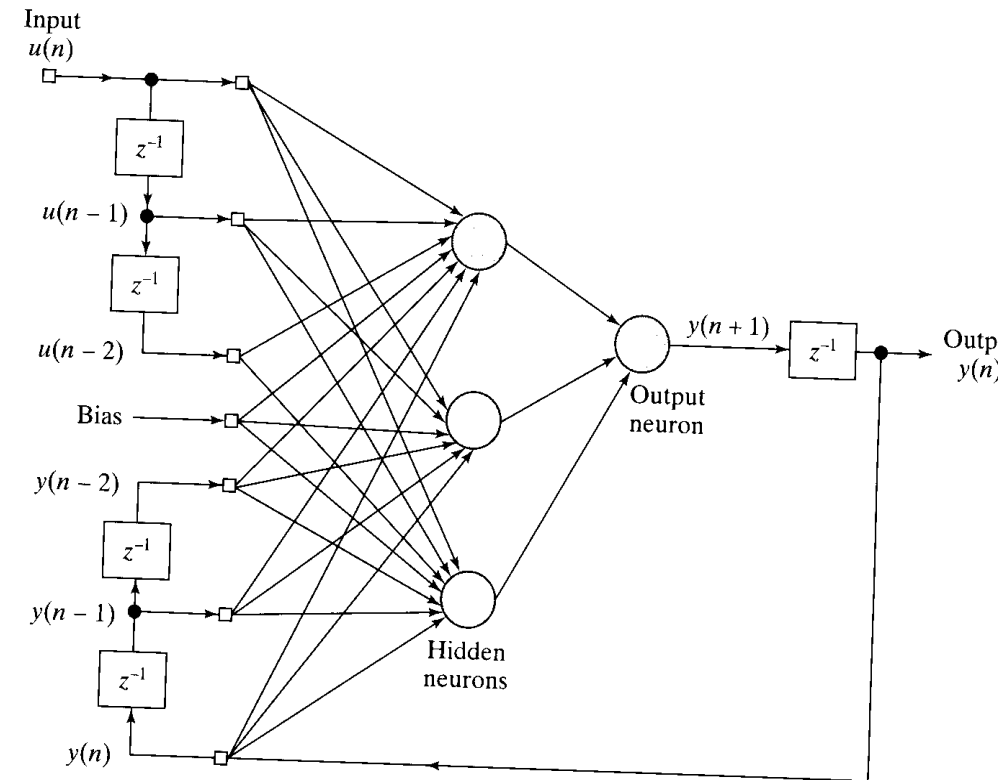



FIGURE 15.7 NARX network with  $q = 3$  hidden neurons.



# Rozmyte sieci neuronowe




# Model NARMAX a model Takagi-Sugeno




- Przykład: funkcja nieliniowa

$$y = \left(1 + x_1^{-2} + x_2^{-1.5}\right)^2$$

$$x_1 \in \langle 1, 5 \rangle \quad x_2 \in \langle 1, 5 \rangle$$




# Model NARMAX a model Takagi-Sugeno



## Przykład – kocioł fluidalny OFz-450

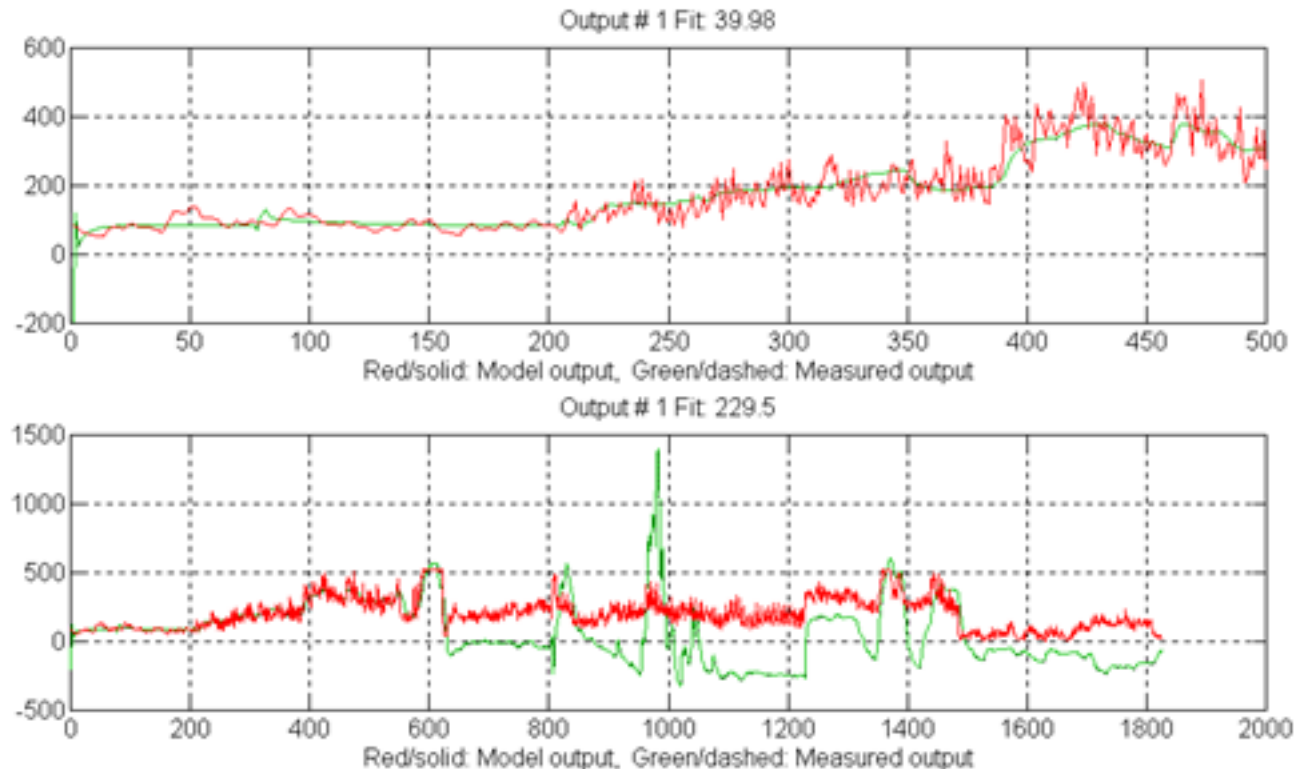
- Przekroczenia emisji  $\text{SO}_2$
- Układ sterowania dozowania sorbentu (kamień wapienny)
- Różne modele
  - Model liniowy Box-Jenkins
  - AFNN
  - model jakościowy otrzymany koewolucyjnie
  - model Takagi-Sugeno: fuzzy neural network (FNN);

### PROCESS SCHEMATIC REPRESENTATION



## Przykład – kocioł fluidalny OFz-450

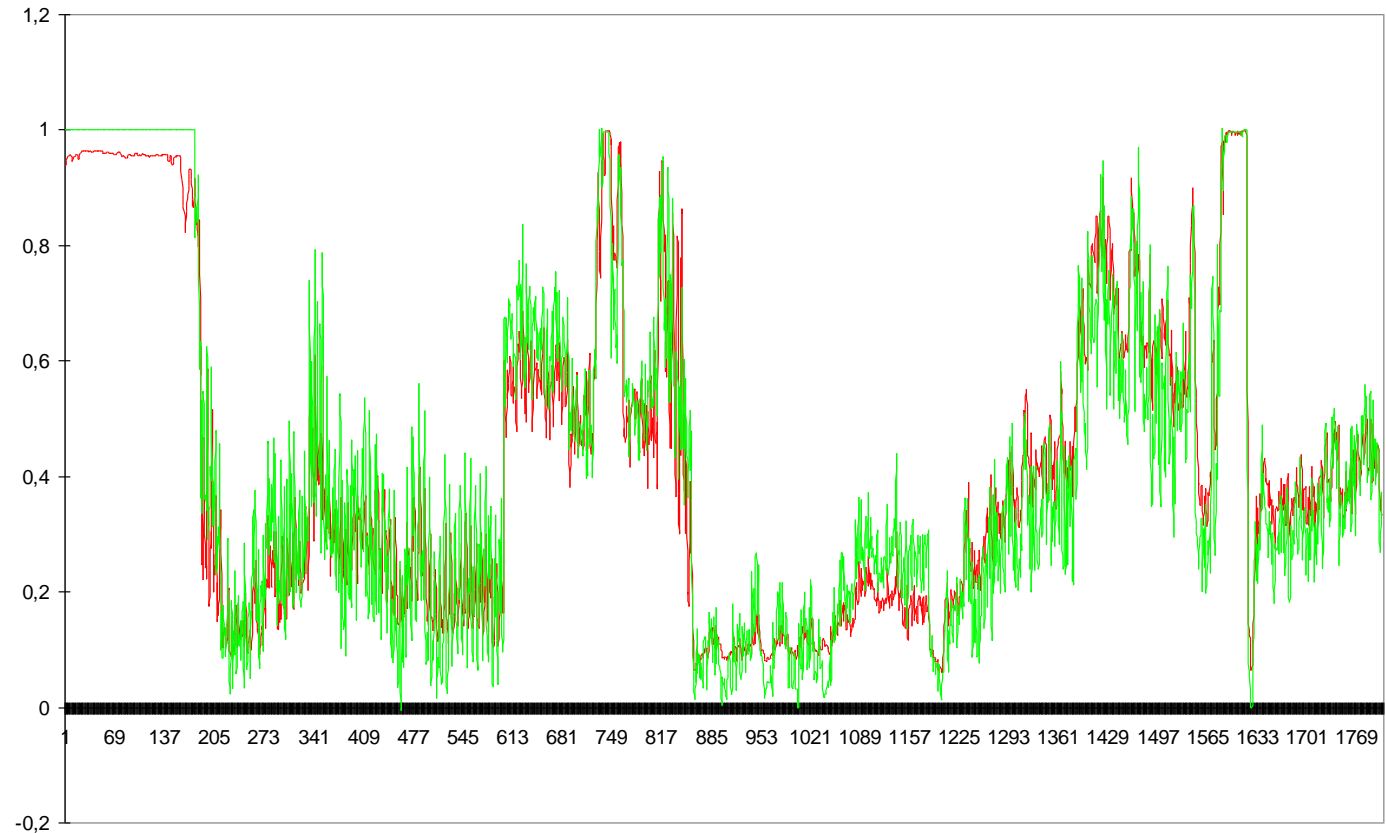
- Model liniowy
- 5 inputs:
  - steam production;
  - primary air flow;
  - sorbent quantity;
  - temperature at level 2;
  - temperature at level 4.
- polynomial orders:
  - $\{N_A, N_B, N_C, N_D, N_F, d\}$
  - $\{1, [2, 2, 5, 1, 1], 0, 0, [3, 5, 6, 2, 2], [1, 1, 0, 0, 0]\}$



# Przykład – kocioł fluidalny OFz-450

- ANN



- input coal flow;
- primary air flow;
- sorbent quantity;
- temperature at level 1;
- temperature at level 2;
- temperature at level 4.
- past  $\text{SO}_2$  emission;
- past  $\text{CO}$  emission;
- past  $\text{O}_2$  concentration.



# Przykład – kocioł fluidalny OFz-450

- Model koewolucyjny

- primary air flow;
- sorbent quantity;
- boiler load;
- temperature at level 2;
- temperature at level 4.
- past  $\text{SO}_2$  emission;

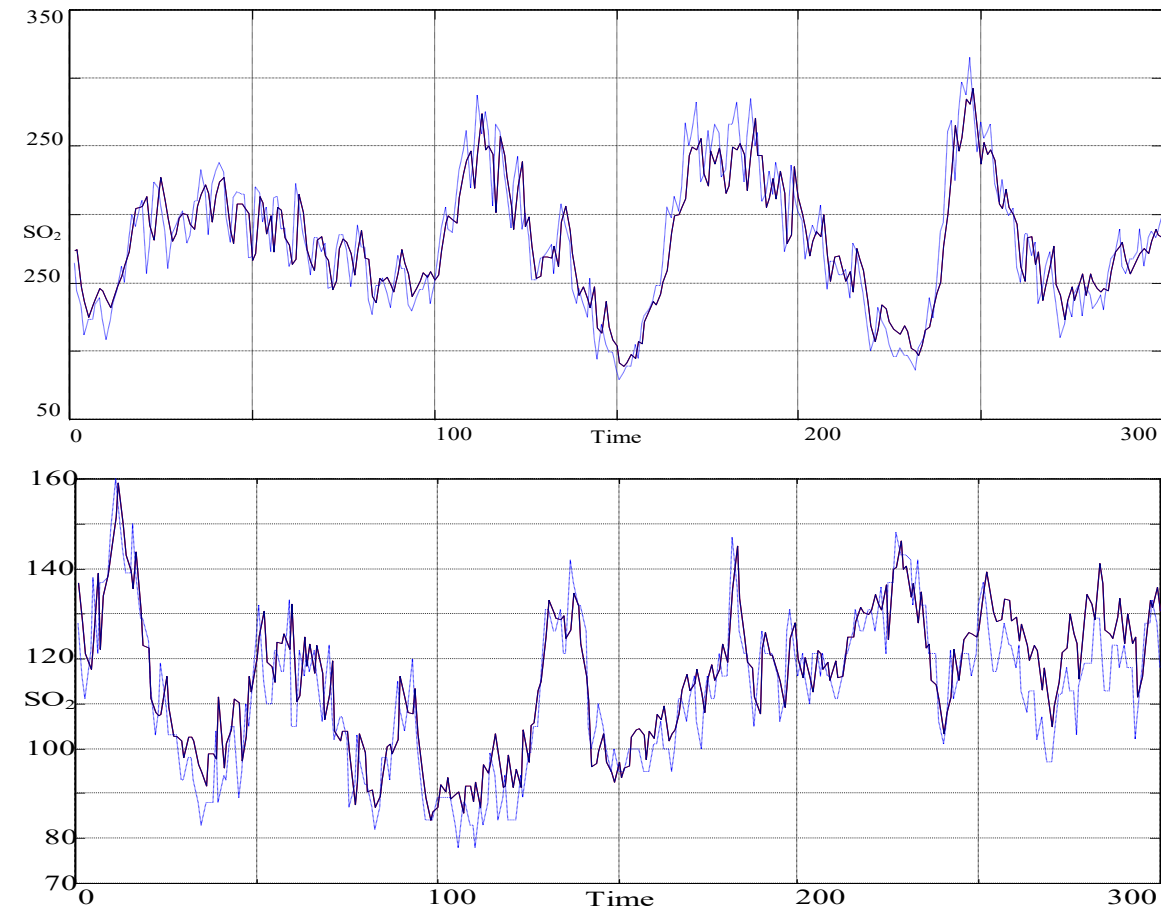




# Przykład – kocioł fluidalny OFz-450

- NARMAX: Takagi-Sugeno


- steam flow;
- primary air flow;
- sorbent quantity (k)moment;
- sorbent quantity (k-1)moment;
- temperature at level 2;
- temperature at level 4.
- past  $\text{SO}_2$  emission (k-1)moment;
- past  $\text{SO}_2$  emission (k-2)moment;



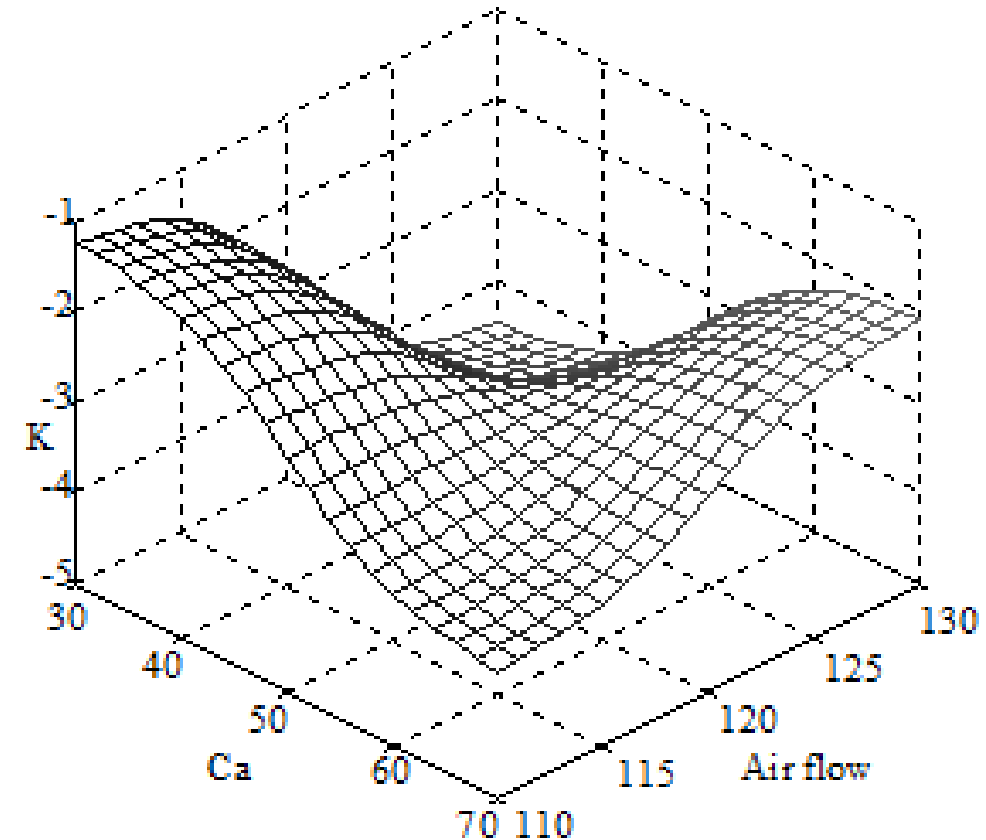


## Przykład – kocioł fluidalny OFz-450

niskie temperatury



wysokie temperatury



wzmocnienie  $K=SO_2/Ca$  w zależności od dopływu kamienia i powietrza

# Szeregi Volterra

- Modele całkowe wysokich rzędów w postaci ciągu całek

- w wersji ciągłej

$$y(t) = \int_{-\infty}^{\infty} h_1(t) u(t - \tau) d\tau$$

$$+ \iint h_2(\tau_1, \tau_2) u(t - \tau_1) u(t - \tau_2) d\tau_1 d\tau_2$$

$$+ \iiint h_3(\tau_1, \tau_2, \tau_3) u(t - \tau_1) u(t - \tau_2) u(t - \tau_3) d\tau_1 d\tau_2 d\tau_3$$

+...

- w wersji dyskretnej

$$y(k) = \sum_{j=1}^{\infty} h_1(j) u(k - j)$$

$$+ \sum \sum h_2(j_1, j_2) u(k - j_1) u(k - j_2)$$

$$+ \sum \sum \sum h_3(j_1, j_2, j_3) u(k - j_1) u(k - j_2) u(k - j_3)$$

+...



# Szeregi Volterra

- Modele zawierają jądro (kernel, funkcja bazowa) w postaci

$$h_3(\tau_1, \tau_2, \dots, \tau_n)$$

- odpowiadające odpowiedzi impulsowej

- Jeśli przyjmiemy, że rząd jest ograniczony do  $k < M$ , to otrzymamy postać

$$y(k) = c_{00} + \sum_{n=1}^p v_M^n(k)$$

$$v_M^n = \sum_{i_1=0}^M \cdots \sum_{i_n=1}^M \alpha_n(i_1, \dots, i_n) u(k - i_1) \dots u(k - i_n)$$

- Inna postać ograniczona do rzędu  $p$

$$A(q^{-1})y(k) = c_{00} + B_1(q^{-1})u(k - d)$$

$$+ \sum_{\beta_1=0}^h B_{2\beta_1}(q^{-1})u(k - d)u(k - d - \beta_1) + \dots$$

$$+ \sum_{\beta_1=0}^h \sum_{\beta_2=\beta_1}^h \cdots \sum_{\beta_{p-1}=\beta_{p-2}}^h B_{p\beta_1\beta_2\dots\beta_{p-1}}(q^{-1})u(k - d) \prod_{\xi=1}^{p-1} u(k - d - \beta_\xi) + \dots$$

często ograniczane do rzędu drugiego

# Aproksymacja za pomocą wielomianów ortogonalnych

- Postać wielomianu aproksymującego

$$Q(x) = \sum_{k=0}^m c_k \varphi_k(x)$$

- Ciąg funkcji jest ortogonalny gdy:

$$\sum_{i=0}^n \varphi_k(\mathbf{x}_i) \cdot \varphi_l(\mathbf{x}_i) = 0 \text{ dla } k, l = 0, 1, \dots, k \neq l$$



# Wielomiany Legendre'a

- Postać rekurencyjna

$$L_0(x) = 1$$

$$L_1(x) = x$$

$$L_{n+1}(x) = \left( \frac{2n+1}{n+1} \right) x L_n(x) - \left( \frac{n}{n+1} \right) L_{n-1}(x) \quad n=1,2,\dots$$

- Wielomian Legendre'a


$$P_k(x) = \frac{1}{2^k \cdot k!} \cdot \frac{d^k}{dx^k} (x^2 - 1)^k$$

- Wielomiany są ortogonalne w dziedzinie  $x \in \langle -1, 1 \rangle$

$$C_k = \frac{\sum_{i=0}^n y_i \cdot P_k(x_i)}{\sum_{i=0}^n P_k^2(x_i)}$$



# 5 pierwszych wielomianów Legendre'a



$$P_0(x) = 1$$

$$P_1(x) = x$$

$$P_2(x) = \frac{1}{2}(3x^2 - 1)$$

$$P_3(x) = \frac{1}{2}(5x^3 - 3x)$$

$$P_4(x) = \frac{1}{8}(35x^4 - 30x^2 + 3)$$

$$P_5(x) = \frac{1}{8}(63x^5 - 70x^3 + 15x)$$

# Wielomiany Czebyszewa

## Wzór ogólny

$$T_0(x) = 1$$

$$T_1(x) = x$$

$$T_2(x) = 2x^2 - 1$$

$$T_n(x) = 2xT_{n-1}(x) - T_{n-2}(x)$$

$$T_0(x) = 1$$

$$T_1(x) = x$$

$$T_2(x) = 2x^2 - 1$$

$$T_3(x) = 4x^3 - 3x$$

$$T_4(x) = 8x^4 - 8x^2 + 1$$

$$T_5(x) = 16x^5 - 20x^3 + 5x$$

$$T_6(x) = 32x^6 - 48x^4 + 18x^2 - 1$$

$$T_7(x) = 64x^7 - 112x^5 + 56x^3 - 7x$$

$$U_0(x) = 1$$

$$U_1(x) = 2x$$

$$U_2(x) = 4x^2 - 1$$


$$U_3(x) = 8x^3 - 4x$$

$$U_4(x) = 16x^4 - 12x^2 + 1$$

$$U_5(x) = 32x^5 - 32x^3 + 6x$$

$$U_6(x) = 64x^6 - 80x^4 + 24x^2 - 1$$

$$U_7(x) = 128x^7 - 192x^5 + 80x^3 - 8x$$



# Wielomiany Laguerre'a

$$L_n(x) = \frac{e^x}{n!} \frac{d^n}{dx^n} (x^n e^{-x}) \rightarrow L_n \text{ ortogonalny na } [0, \infty]$$

$$(n+1)L_{n+1}(x) = (2n+1-x)L_n(x) - nL_{n-1}(x)$$

$$L_0^{(\alpha)}(x) = 1$$

$$L_1^{(\alpha)}(x) = -x + \alpha + 1$$

$$L_2^{(\alpha)}(x) = \frac{1}{2}x^2 - (\alpha+2)x + \frac{(\alpha+1)(\alpha+2)}{2}$$

$$L_3^{(\alpha)}(x) = -\frac{1}{6}x^3 + \frac{\alpha+3}{2}x^2 - \frac{(\alpha+2)(\alpha+3)}{2}x + \frac{(\alpha+1)(\alpha+2)(\alpha+3)}{6}$$

$$0! L_0(x) = 1$$

$$1! L_1(x) = 1 - x$$

$$2! L_2(x) = x^2 - 4x + 2$$

$$3! L_3(x) = -x^3 + 9x^2 - 18x + 6$$

$$4! L_4(x) = x^4 - 16x^3 + 72x^2 - 96x + 24$$

$$5! L_5(x) = -x^5 + 25x^4 - 200x^3 + 600x^2 - 600x + 120$$

$$6! L_6(x) = x^6 - 36x^5 + 450x^4 - 2400x^3 + 5400x^2 - 4320x + 720$$

$$7! L_7(x) = -x^7 + 49x^6 - 882x^5 + 7350x^4 - 29400x^3 + 52920x^2 - 35280x + 5040$$

